ElVino

Adrian Hauge, Nanthawat Dahl, Magnus Granås, 29.10.2025

1: BESKRIV PROBLEMET

OMFANG / *SCOPE*

Formålet er å predikere vin kvalitet basert på målinger fra datasett. Kvalitetsvariabelen som «quality» i datasettet er gitt på en skala fra 1 til 10. I prosjektet er problemet behandlet som en binær klassifikasjonsoppgave, god mot dårlig vin. Modellen brukes til å vise og hjelpe kunder med å foreta raske vurderinger av vin kvalitet uten å måtte kjøpe vinen først.

Maskinlæring er godt egnet til denne slags type problem, fordi den sammenhenger mellom de kjemiske egenskapene i vinen. De ulike kjemiske variablene påvirker hverandre, dette er vanskelig å fange opp gjennom enkle metoder. En maskinlæringsmodell kan identifisere disse mønstrene og avhengigheter i dataen som ikke er merkbar for mennesker, og gi mer presise og konsistente kvalitetsvurderinger. I tillegg skaleres modellen kontinuerlig og automatiserer vurderinger uten behov for manuell innsats.

Alternativt kunne oppgaven være løst manuelt av kunder selv smaker vinene, og legger inn vurderinger selv. Systemet kunne da beregnet gjennomsnittet av vurderingene som et mål på kvalitet. Denne metoden ville vært tidskrevende, krevd flere deltakere for å oppnå pålitelighet. Det kan også være utsatt for subjektive forskjeller i smakspreferanse. En maskinlæringsbasert tilnærming er derfor mer objektiv, effektiv og skalerbar løsning.

METRIKKER

Evaluering av modellen skjer på to nivåer. Forretningsmessige metrikker og maskinlæring metrikker. Forretningsmessige metrikker viser hvilken verdi løsningen skaper for brukere. Samt maskinlæring metrikkene måler ytelsen til modellen.

Forretningsmessige metrikker

For kundene er hovedmålet å få en pålitelig indikasjon på vin kvalitet uten å måtte kjøpe vinen først. Den sentrale forretningsmetrikk, brukertilfredshet, som måles gjennom graden som samsvar mellom modellens prediksjon og kundens opplevelse av vinen er faktisk objektivt kvalitet etter kjøp.

Maskinlæring Metrikker

På det tekniske nivået vurderes modellens ytelse gjennom metrikker for klassifikasjon problemer:

- **Presisjon:** Andelen av vinene som modellen bruker for å klassifisere som «Bra» kvalitet, som faktisk viser objektivt bra kvalitet. Denne metrikken måles for å unngå feil anbefalinger til kunden.

- **Recall:** Andelen av de vinene som faktisk er av høy kvalitet, som modellen indentifiserer. Et høyt recall nivå sikrer at gode viner ikke blir hoppet over.

- **F1-score:** Dette er gjennomsnittet av presisjon og recall, dette blir brukt som ett mål, når det er viktig for både å identifisere alle gode kvalitet vin og unngå feilklassifiseringer.

- **Forvekslingsmatrise:** Brukes for å analysere hvilke kvalitetkategorier som blir feiltolket og danner et grunnlag for forbedringer av modellen.

[1] https://www.gradio.app

2: DATA

I henhold til datasettet «***Wine Quality***» brukes det 11 variabler med rollen feature:

- **Fixed_acidity**
- **Volatile_acidity**
- **Citric_acidity**
- **Residual sugar**
- **Chlorides**
- **Free_sulfur_dioxide**
- **Total_sulfur_dioxide**
- **Density**
- **pH**
- **Sulphates**
- **Alcohol**

I tillegg til disse variablene brukes målet «kvalitet» og fargen til vinen. Vi fant gjennom gjentatte prøver at «Alcohol» variabelen er en dominerende variabel for «kvalitet», så det kan oppstå problemer med kvaliteten hvis prosenten er veldig høy. Når vi inspiserte korrelationene mellom features-ene fant vi at «***Free_Sulfur_dioxide***» og «***Total_sulfur_dioxide***» hadde høy korrelasjon, se figuren under. Ved en kjapp test konkluderte med at å fjerne «***Free_Sulfur_dioxide***» gav best resultat for modellen.

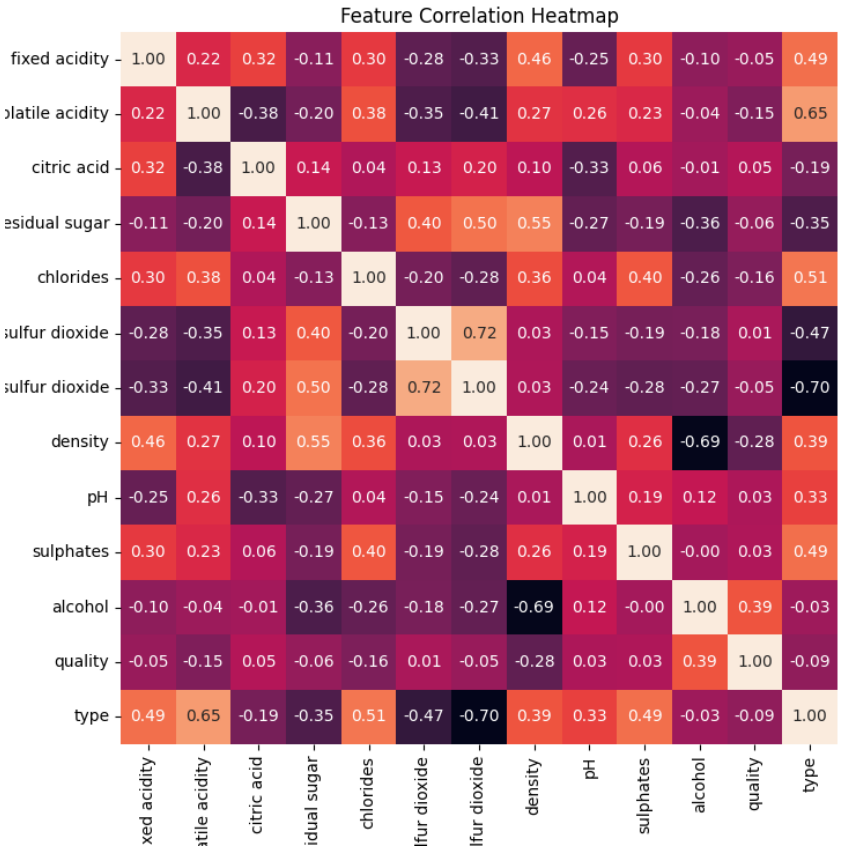

Datasettet vi har valgt er allerede veldig komplett da ingen verdier mangler på variablene, men som du kan se på figuren under, er datasettet veldig ubalansert.

[1] https://www.gradio.app

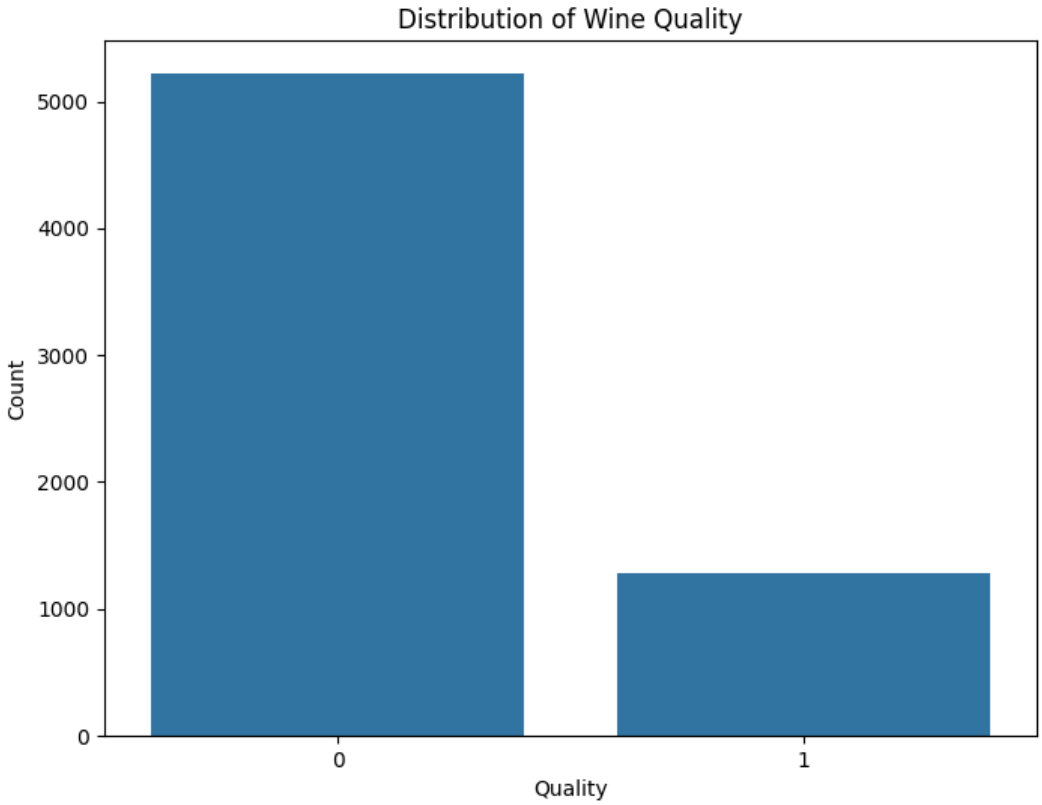

For å unngå at modellen for et bias mot majoritetsklassen har vi valgt å balansere datasettet ved hjelp av SMOTE-teknikken. SMOTE er en algoritme som genererer nye datapunkt i minoritetsklassen ved å kombinere datapunkt i minoritetsklassen ved deres nærmeste nabo i *feature space.*

Under kan du se et vedlegg av hvor mye de forskjellige variablene spiller på kvaliteten.

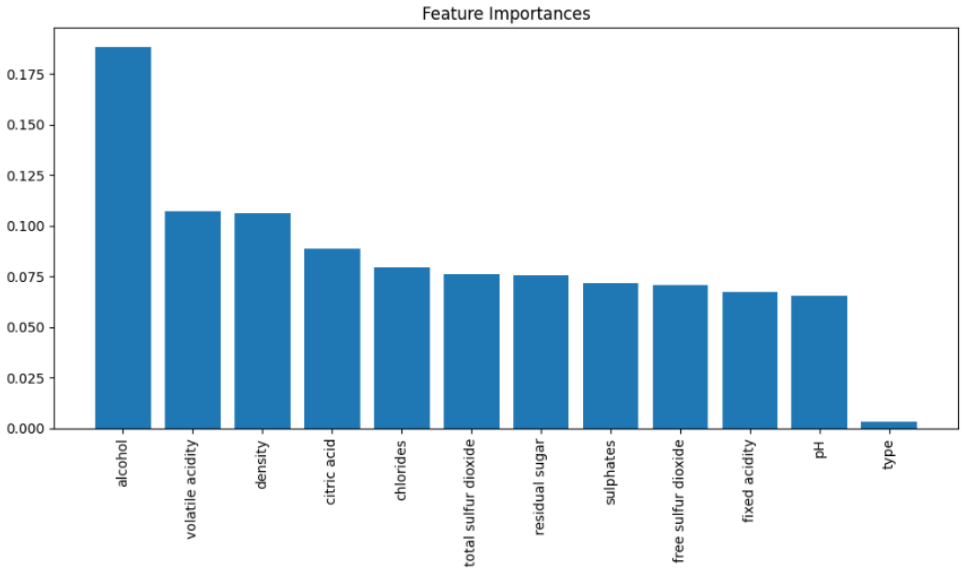

[1] https://www.gradio.app

3: MODELLERING

Vi brukte RandomForestClassifier som hovedmodell. Random Forest er en ensemble metode som kombinerer mange beslutningstrær for å oppnå høyere nøyaktighet og robusthet enn enkelttrær. Modellen håndterer kontinuerlige og kategoriske variabler, og den gir samtidig innsikt i feature importance, noe som gjør den egnet for prediksjon og tolkning. Vi har evaluert modellen vår fra metrikkene F1 score, Accuracy og recall.

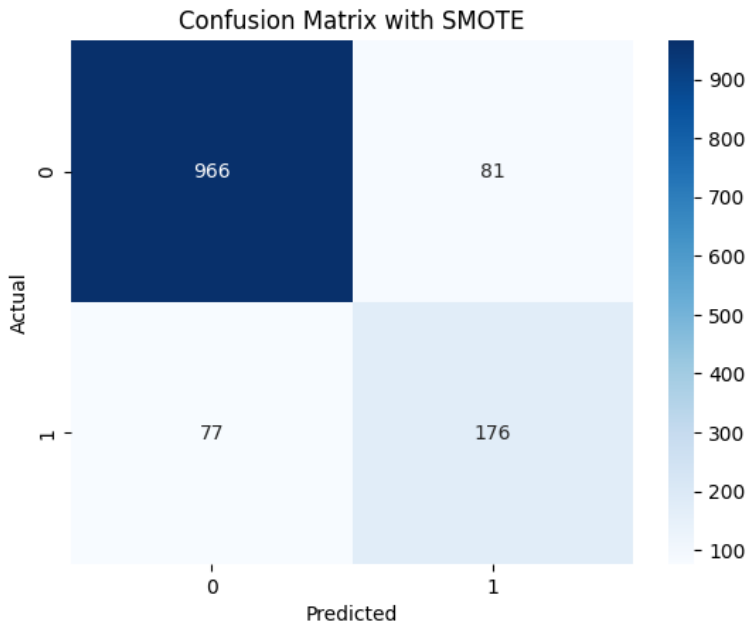

4: DEPLOYMENT

Modellen settes i drift ved bruk av gradio[1] som gir en enkel løsning med et brukervennlig grensesnitt. Hosting av websiden skjer gjennom AWS som er en sky basert løsning som gjør det enkelt å vedlikeholde og se etter feil i koden.

5: REFERANSER

Paulo C, Cerdeira. A, Almeida. F, Matos. T, Reis. J (2009). “Wine quality”
https://archive.ics.uci.edu/dataset/186/wine+quality

[1] https://www.gradio.app